Tìm ảnh văn hoá Việt Nam

Tìm ảnh bằng một câu tiếng Việt: vector ảnh, vector văn bản và từ khoá trong Qdrant, sắp xếp lại bằng rerank trên CPU. Gemini chỉ để hiểu câu hỏi, không dùng agent để tìm ảnh.

0
ảnh được index và truy xuất

0
loại truy vấn: một ý, nhiều ý, suy luận

0/10
truy vấn mới dưới 3 giây trên VPS (p95 2,3 giây)

0
test tự động; CI và CD tự động lên VPS

Bài toán và ràng buộc

Đề bài

Ít nhất 80.000 ảnh, chạy bằng **docker compose**, có web demo.

Độ trễ dưới 3 giây cho cả ba loại truy vấn.

Chỉ dùng embedding và rerank để tìm ảnh; LLM chỉ xử lý truy vấn (Gemini 3.5 Flash Lite).

Endpoint **/embed**, **/rerank** có API key để chấm tự động.

Ba loại truy vấn

Một ý: "cầu Long Biên".

Nhiều ý: "áo dài Huế và nhà thờ Phát Diệm": top 10 phải phủ cả hai ý.

Suy luận: "nghệ thuật sân khấu dân gian miền Bắc": phải suy ra các thực thể cụ thể.

Ràng buộc phần cứng

Lập chỉ mục trên laptop có GPU RTX 3050 4 GB; phục vụ hoàn toàn trên **CPU** (laptop Ryzen 7 6800H, VPS 8 vCPU), không GPU.

Dữ liệu là ảnh di sản văn hoá của nhóm: các câu về du lịch biển hay động vật hoang dã không có ảnh đúng, hệ thống gắn cảnh báo thay vì giả vờ chắc chắn.

Tách luồng ngoại tuyến và trực tuyến

Ngoại tuyến: một lần, máy dev có GPU

Dữ liệu team
21 file Excel, cờ Giữ/Bỏ

→

Manifest
92.339 URL

→

Tải, chuẩn hoá
WebP ≤ 640 px, pHash gom ảnh gần trùng

→

S3
ảnh WebP và snapshot index

→

Embed
SigLIP2 B/16 (ảnh), bge-m3 (văn bản)

→

Qdrant
89.596 điểm, 3 vector, INT8

Trực tuyến: mỗi truy vấn, CPU, docker compose

Truy vấn
chuẩn hoá NFC, cache LRU

→

Gemini, một lệnh gọi
loại truy vấn, tách ý, thực thể

→

Đối chiếu thực thể
bỏ thực thể không có trong dữ liệu

→

Embed truy vấn
mỗi ý một lượt

Qdrant hybrid
ba nhánh, hợp nhất bằng RRF

→

Hạn ngạch theo ý
tối đa 3 ảnh mỗi thực thể

→

Rerank
16 ứng viên, có ngân sách thời gian

→

Top 10
gộp ảnh gần trùng

Dịch vụ: caddy (HTTPS) · qdrant · api (FastAPI: /search, /embed, /rerank, /healthz và giao diện web).

Từ file Excel đến index tìm được

Bước	Kết quả (đo 18/10/2026)
Manifest	92.339 URL giữ lại từ 21 file Excel (ô Giữ/Bỏ trống tính là giữ)
Tải ảnh	**89.596 ảnh (97,03%)**, WebP cạnh dài ≤ 640 px, khoảng 52 KB mỗi ảnh; lên S3 không lỗi
Ảnh gần trùng	pHash, Hamming ≤ 4: không loại khỏi index mà gắn **dup_group** và gộp lúc trả kết quả (loại thẳng sẽ xuống dưới 80.000 ảnh)
Embed ảnh	SigLIP2 B/16, FP16, batch 64: khoảng 85 phút trên RTX 3050
Embed văn bản	bge-m3, FP16: khoảng 25 phút; văn bản ghép từ tên thực thể, thể loại, địa bàn, mô tả, chú thích ảnh, tiêu đề trang
Nạp Qdrant	89.596 điểm, 3 vector mỗi điểm, scalar INT8; snapshot 1,04 GB trên S3, **đã khôi phục thử vào máy trống**

Một pipeline cho ba loại truy vấn

Một ý

"cầu Long Biên"

Tìm thẳng bằng ba nhánh: cụm tiếng Anh cho vector ảnh, văn bản tiếng Việt cho vector văn bản và từ khoá.

Nhiều ý

"áo dài Huế và nhà thờ Phát Diệm"

Gemini tách thành hai ý, mỗi ý tìm riêng rồi **xen kẽ theo hạn ngạch** để không ý nào chiếm hết top 10.

Suy luận

"nghệ thuật sân khấu dân gian miền Bắc"

Gemini suy ra thực thể cụ thể, đối chiếu với dữ liệu; vẫn tìm cả truy vấn gốc và từng thực thể suy ra.

Hybrid trong Qdrant

Mỗi ý có ba nhánh (ảnh, văn bản, sparse), mỗi nhánh 50 ứng viên, hợp nhất bằng **RRF**: không phải chuẩn hoá điểm giữa các thang khác nhau.

Rerank có ngân sách

Cross-encoder chấm 16 ứng viên, mỗi ảnh so với đúng truy vấn con của nó; chỉ chạy khi còn dư địa thời gian (trần 2,7 giây).

Cải tiến ngày 21/10: không nối thực thể Gemini đoán vào văn bản tìm. Chỉ truy xuất, bộ v1: suy luận 0,30 → 0,45, một ý 0,92 → 1,00.

Collection images trong Qdrant

Vector của mỗi ảnh

```
img     768   SigLIP2 B/16
              cosine, INT8
txt     1024  bge-m3 dense
              cosine, INT8
sparse  -     bge-m3 lexical weights
```

Payload

```
image_id      khoá ảnh
entity_ids    thực thể gắn với ảnh
entity_names  tên thực thể đã duyệt
caption       mô tả ảnh
page_title    tiêu đề trang nguồn
branch        nhánh phân loại
region        địa bàn
dup_group     nhóm ảnh gần trùng
```

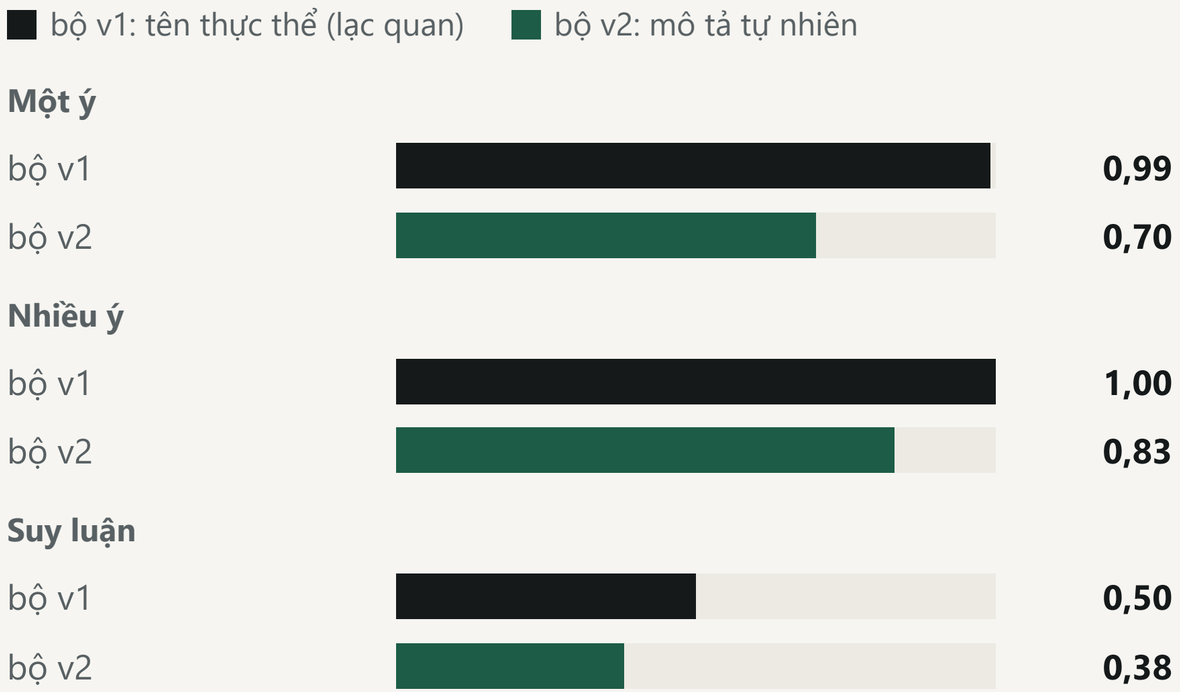
Văn bản được index cho nhánh văn bản và sparse

[Thực thể | Phân loại | Địa bàn | Thể loại]. Mô tả thực thể. Chi tiết ảnh. Nguồn. Nhờ vậy truy vấn "thể loại + vùng" khớp trực tiếp, và tên riêng được nhận ra mà không cần nhìn pixel.

Vì sao chọn như vậy

Hybrid, không chỉ vector ảnh	Vector ảnh không biết tên riêng. Recall@10 bộ v1: chỉ ảnh 0,32 / 0,35 / 0,11; hybrid 0,93 / 0,99 / 0,34
RRF để hợp nhất	Ba nhánh khác thang điểm; RRF chỉ dùng thứ hạng
Gemini một lệnh gọi, timeout 1,6 giây	p50 thực đo khoảng 1 giây. Lỗi thì tách ý bằng quy tắc, không trả lỗi 500
Không nối thực thể đoán vào văn bản tìm	Thực thể đoán sai kéo kết quả lạc. Đo trên bộ v2 (chỉ truy xuất): một ý 0,55 → 0,675; nhiều ý 0,775 → 0,875; suy luận 0,35 → 0,40
Giữ ảnh gần trùng, gộp lúc trả	Loại thẳng sẽ xuống dưới 80.000 ảnh
Rerank có ngân sách thời gian	Luôn chạy làm p50 vượt 3 giây khi hai luồng; chỉ cộng khoảng +0,03 Recall@10
Rerank của mentor (tuỳ chọn)	Cùng Recall@10 với bộ local, nhanh hơn: **140-323 ms** so với 640-940 ms; tự quay về local khi lỗi
Không agent, không VLM khi tìm ảnh	Đúng ràng buộc đề bài; LLM chỉ dùng để hiểu truy vấn

Chất lượng: Recall@10



Đo 21/10/2026, hybrid + rerank. Bộ v1: 300 truy vấn. Bộ v2: 40 truy vấn mỗi loại.

Cách tạo test case

Bộ v1 sinh từ tên thực thể và quan hệ, không từ chú thích đã index. Bộ v2 do Gemini viết từ mô tả thực thể, **không chứa tên** (kiểm tra tự động).

Điểm cần nói thẳng

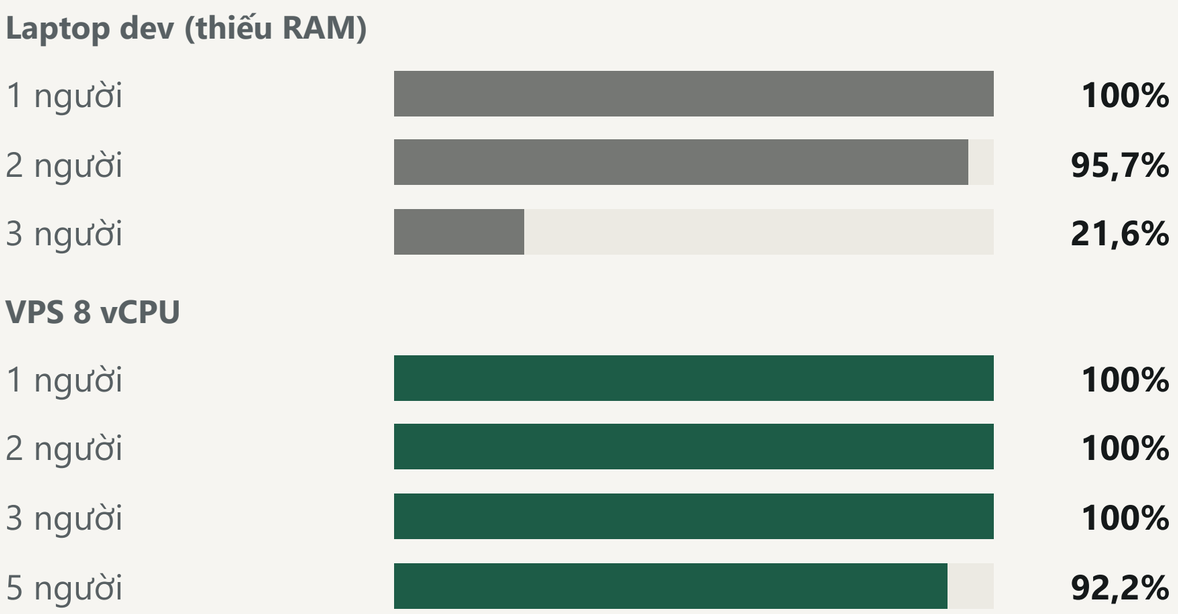
Bộ v1 lạc quan vì câu một ý chính là tên thực thể. Số sát thực tế hơn là bộ v2. Duyệt tay bộ v1: 44/45 đúng, 1 mơ hồ.

60 câu kiểm tra tay

Tự chấm tay: dễ khoảng 19/20, khó khoảng 16/20 đúng hẳn; **câu mô tả cảnh không có tên riêng yếu nhất** (khoảng 14-15/20).

Độ trễ và tải

Tỉ lệ /search dưới 3 giây (k6, nhiều người dùng đồng thời)



2,3 s

p95 trên VPS, 10 truy vấn mới, tất cả dưới 3 giây (1 người dùng)

2,1

yêu cầu mỗi giây trên VPS (laptop khoảng 1)

Rerank qua endpoint của mentor: **140-323 ms**, so với 640-940 ms của model local trên CPU.

Laptop chỉ còn khoảng 0,5-0,9 GB RAM trống khi đo nên truy vấn dao động 1-22 giây. Báo cáo k6 HTML và JSON tự sinh, chạy lại bằng loadtest/run.sh.

Hạn chế và chưa làm

Hạn chế đã biết

Suy luận vẫn yếu nhất: 0,50 (bộ v1), 0,38 (bộ v2).

Câu mô tả cảnh bằng hình ảnh, không có tên riêng, hay ra sai nhóm.

Cảnh báo "độ tin cậy thấp" chỉ bắt 8/20 câu ngoài dữ liệu; còn khoảng 3,7% cảnh báo oan.

Phụ thuộc Gemini (mạng, khoá) và endpoint rerank tạm của mentor (hạn mức 50 yêu cầu/phút).

Bộ test v2 và 60 câu do một người duyệt, không độc lập.

Chưa làm

ONNX INT8 cho rerank, ColBERT/maxsim, cache ngữ nghĩa.

Embedding của mentor: vector 2560 chiều không khớp 1024 của index; hạn mức quá thấp để embed lại 89.596 caption.

k6 smoke trong CI (CI chạy lint, test, build Docker; CD đã bật).

Truy vấn quan hệ thật (ví dụ "con trai chủ tịch ...") chưa có trong bộ test.

Hướng cải thiện: thước đo cảnh báo dựa trên độ giống giữa truy vấn và ảnh, duyệt độc lập bộ test, bổ sung chú thích cho nhóm câu mô tả cảnh.

Repo nộp: VSF-AR-ES-V-Lookup/Retrieval_Image_NguyenTuanThanh · Demo: 13-251-152-106.sslip.io · Tài liệu: docs/eval-report.md, docs/perf-report.md, docs/architecture.md